AICE Associate 샘플문항

와인 데이터를 활용한 와인 품질 예측

- 도메인 : 품질 관리(QC)
- 목 표 : 와인의 품질을 예측하는 인공지능모델 개발
- 와인 도매업체인 C사에서 수입하는 와인 품질이 경쟁사 와인 품질 대비 떨어진다는 평가를 받으며 매출이 감소하고 있다.
- 계속되는 매출 부진을 만회하기 위해, C사 품질관리팀장은 수십년간 축적된 공신력 있는 와인평론가의 와인 평가 데이터를 활용해서 '와인품질등급'을 예측하는 인공지능 모델을 도입하려고 한다.
- C사는 브랜드파워가 있기 때문에, 인공지능을 활용해서 '와인품질등급'의 정확도가 개선되어 고품질의 와인만 선별하여 수입하면 매출이 빠르게 회복될 것으로 기대하고 있다.

[유의사항]

- 각 문항의 답안은 반드시 *'#여기에 답안코드를 작성하고 실행하세요' , '#여기에 답안을 입력하세요'* 등이 표시된 셀(cell)에 입력해야 합니다
- 제공된 시험문항 셀을 삭제하거나 답안 위치가 아닌 다른 셀에 답안코드를 작성 시 채점되지 않습니다
- 답안 작성 전에 문항에 제시된 가이드를 확인하세요
- 문항에 변수명이 제시된 경우 반드시 해당 변수명을 사용하세요
- 시험 중에는 상단의 '임시저장' 버튼을 수시로 클릭해 저장해주시고, 답안 제출시에는 '최종제출' 버튼을 클릭해주시기 바랍니다
- **시험 문항과 데이터 등을 무단으로 촬영/캡쳐, 복사/복제, 판매/재판매, 공개/전재, 공유/유포 할 경우 지식재산권 침해에 따른 법적 제재를 받을 수있습니다**
- **오픈북은 허용된 사이트만 참고 가능하며 그 외 자료, 사이트 등을 참고하는 경우 부정행위로 간주됩니다**

[데이터 컬럼 설명 (데이터 파일명: wine_quality_data.csv)]

- Grade : 와인품질등급(Pass, Fail)
- E_title : 와인이름
- E_country : 생산국가
- E_province : 생산지 세부주소 ①
- E_region_1 : 생산지 세부주소 ②
- E_region_2 : 생산지 세부주소 ③
- E_winery : 와이너리(와인 생산 농장명)
- E_FE_vintage : 포도수확연도
- E_wine_variety : 포도품종
- E_FE_wine_kind : 와인종류
- FE_continent : 생산대륙(신대륙/구대륙)
- E_price : 가격
- FE_points_location : 와인 생산지 평점
- FE_points_variety : 포도 품종 평점
- FE_points_winery. : 와이너리 평점

<데이터 분석 (20점)>

> **다음 문항을 풀기 전에 아래 코드를 실행하세요.**

In [1]:
```python
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
```

---

1. scikit-learn은 머신러닝에 널리 사용되는 파이썬 라이브러리입니다.
scikit-learn을 사용할 수 있게 별칭(alias)을 sk로 해서 불러오세요.

In [2]:
```python
# (1) 여기에 답안코드를 작성하고 실행하세요

import sklearn as sk
```

2. AI 모델링을 위해 분석 및 처리할 데이터 파일을 읽어오려고 합니다.
pandas로 데이터 파일을 읽어온 뒤, 데이터프레임 변수명 data 에 할당하고 첫 4개 행을 출력하세요.

- 데이터프레임 변수명 : data
- 데이터 파일명 : wine_quality_data.csv
  - csv 파일은 본 문제/답안지와 동일한 경로에 있습니다

In [3]:
```python
# (2) 여기에 답안코드를 작성하고 실행하세요

import pandas as pd

data = pd.read_csv('./wine_quality_data.csv')
data.head(4)
```

Out[3]:

	Grade	E_title	E_country	E_province	E_region_1	E_region_2	E_winery	E_FE_vintage	E_wine_variety	E_FE_wine_kind	FE_continent	E_price	FE_points_location	FE_points_variety	FE_points_winery
0	Fail	Nicosia 2013 Vulkà Bianco (Etna)	Italy	Sicily & Sardinia	Etna	-	Nicosia	2013	White Blend	white	0	NaN	90.0	87.0	87.0
1	Fail	Quinta dos Avidagos 2011 Avidagos Red (Douro)	Portugal	Douro	-	-	Quinta dos Avidagos	2011	Port	NaN	0	15.0	89.0	88.0	87.0
2	Fail	St. Julian 2013 Reserve Late Harvest Riesling ...	US	Michigan	Lake Michigan Shore	-	St. Julian	2013	Riesling	white|sparkling	1	13.0	86.0	90.0	86.0
3	Fail	Tandem 2011 Ars In Vitro Tempranillo-Merlot (N...	Spain	Northern Spain	Navarra	-	Tandem	2011	Merlot	red|rose|sparkling	0	15.0	86.0	87.0	87.0

3. 시각화를 통해 와인종류(E_FE_wine_kind)와 와이너리 평점(FE_points_winery)의 분포를 파악하려 합니다.

- 대상 데이터프레임 : data
- 와인종류(E_FE_wine_kind)의 분포를 보여주는 countplot 그래프를 그리세요
- 와인등급(Grade) 별 와이너리 평점(FE_points_winery)의 분포를 보여주는 histplot 그래프를 그리세요
- subplots를 활용하여 두 그래프를 가로 방향으로 나란히 그리세요
- 두 그래프의 제목을 각각 'Wine Count'와 'Winery Score'로 설정하세요

- 아래 코드 셀(cell)에 있는 코드의 빈칸을 채우고 실행하세요
- 빈칸에 들어갈 내용은 각 답안 셀(cell)에 입력하세요 (#3-1, #3-2, #3-3)

In [5]:
```python
# (코드 셀) 코드의 빈칸을 채우고 실행하세요

fig, axes = plt.subplots(nrows=1, ncols=2, figsize=(15, 6))

sns.countplot(data=data, x='E_FE_wine_kind', ax=axes[0])
sns.histplot(data=data, x='FE_points_winery', hue='Grade', ax=axes[1])

plt.setp(axes[0].get_xticklabels(), rotation=45, ha='right')

axes[0].set_title('Wine Count')
axes[1].set_title('Winery Score')

plt.show()
```

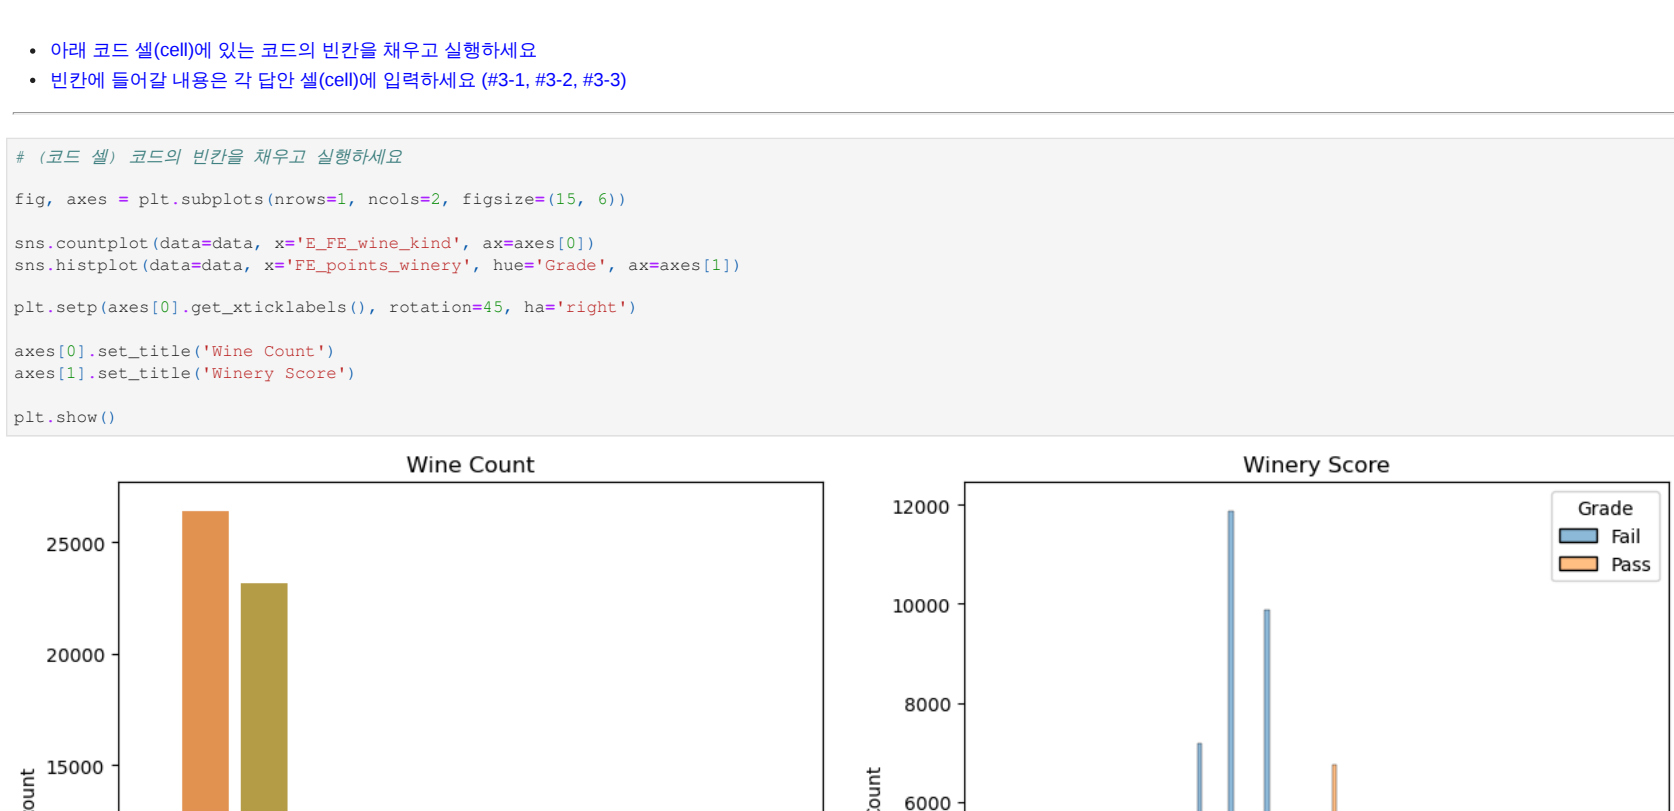

In [ ]:
```python
# (3-1) 여기에 답안을 입력하세요(실행 불필요)

subplots
```

In [ ]:
```python
# (3-2) 여기에 답안을 입력하세요(실행 불필요)

axes
```

In [ ]:
```python
# (3-3) 여기에 답안을 입력하세요(실행 불필요)

set_title
```

4. 그래프를 통해 와인품질등급(Grade) 별 와이너리 평점(FE_points_winery) 컬럼의 분포를 확인하려 합니다.
아래 가이드에 따라 boxplot으로 시각화하세요.

- 대상 데이터프레임 : data
- seaborn의 boxplot으로 와이너리 평점(FE_points_winery) 컬럼의 분포를 그래프로 그리세요
- X축에는 와인품질등급(Grade)을, Y축에는 와이너리 평점(FE_points_winery)을 표시하세요

In [6]:
```python
# (4) 여기에 답안코드를 작성하고 실행하세요

sns.boxplot(data=data, x='Grade', y='FE_points_winery')
```

Out[6]:
```
<Axes: xlabel='Grade', ylabel='FE_points_winery'>
```

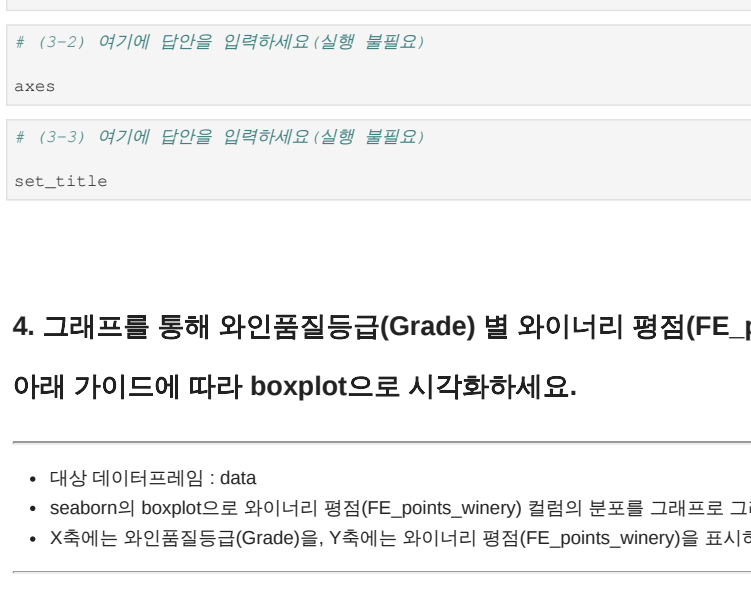

<데이터 전처리 (30점)>

5. boxplot으로 확인한 결과, 와이너리 평점(FE_points_winery) 컬럼에서 이상치가 발견되었습니다. AI모델링할때 부정적 영향이 없도록 아래 가이드에 따라 이상치를 처리하세요.

- 대상 데이터프레임 : data
- 와이너리 평점이 upperfence 값보다 큰 이상치가 있는 행(row)을 삭제하세요
- 와이너리 평점이 lowerfence 값보다 작은 이상치가 있는 행(row)을 삭제하세요
- AI모델링에 불필요한 와인이름(E_title) 컬럼을 삭제하세요
- 전처리를 적용한 데이터프레임은 data_temp라는 변수명으로 저장하세요

- 아래 코드 셀(cell)에 있는 코드의 빈칸을 채우고 실행하세요
- 빈칸에 들어갈 내용은 각 답안 셀(cell)에 입력하세요 (#5-1, #5-2)

In [7]:
```python
# (코드 셀) 코드의 빈칸을 채우고 실행하세요

q1 = data['FE_points_winery'].quantile(0.25)
q3 = data['FE_points_winery'].quantile(0.75)
iqr = q3 - q1

lower_fence = q1 - 1.5 * iqr
upper_fence = q3 + 1.5 * iqr

data_temp = data.drop( data[(data['FE_points_winery'] > upper_fence) | (data['FE_points_winery'] < lower_fence)].index, axis=0)
data_temp = data_temp.drop( columns=['E_title'], axis=1)
data_temp.reset_index(drop=True, inplace=True)
```

In [ ]:
```python
# (5-1) 여기에 답안을 입력하세요(실행 불필요)

drop
```

In [ ]:
```python
# (5-2) 여기에 답안을 입력하세요(실행 불필요)

index
```

6. 데이터에 결측치가 있을 경우 AI모델링의 성능이 저하될 수 있습니다. AI모델링할때 부정적 영향이 없도록 아래 가이드에 따라 결측치를 처리하세요.

- 대상 데이터프레임 : data_temp
- 결측치 개수를 확인한 후에 결측치가 있는 행을 모두 삭제하세요
- 전처리가 반영된 데이터프레임은 변수명 data_na에 저장하세요
- 결측치가 사라졌는지 확인하세요
- 아래 코드 셀(cell)에 있는 코드의 빈칸을 채우고 실행하세요
- 빈칸에 들어갈 내용은 각 답안 셀(cell)에 입력하세요 (#6-1, #6-2)

In [8]:
```python
# (코드 셀) 코드의 빈칸을 채우고 실행하세요

print( '결측치 처리 전\n', data_temp.isnull().sum() )
data_na = data_temp.dropna()
print( '결측치 처리 후\n', data_na.isnull().sum() )
```

```
결측치 처리 전
 Grade                   0
E_country               0
E_province              0
E_region_1              0
E_region_2              0
E_winery                0
E_FE_vintage            0
E_wine_variety          0
E_FE_wine_kind       3746
FE_continent            0
E_price              6902
FE_points_location      0
FE_points_variety       0
FE_points_winery        0
dtype: int64
결측치 처리 후
 Grade                0
E_country            0
E_province           0
E_region_1           0
E_region_2           0
E_winery             0
E_FE_vintage         0
E_wine_variety       0
E_FE_wine_kind       0
FE_continent         0
E_price              0
FE_points_location   0
FE_points_variety    0
FE_points_winery     0
dtype: int64
```

In [ ]:
```python
# (6-1) 여기에 답안을 입력하세요(실행 불필요)

isnull
```

In [ ]:
```python
# (6-2) 여기에 답안을 입력하세요(실행 불필요)

dropna
```

7. 원-핫 인코딩(One-Hot Encoding)은 범주형 데이터를 1과 0의 이진형 벡터로 변환하기 위해 사용하는 방법입니다.
아래 가이드에 따라 범주형 데이터를 이진형 벡터로 변환하는 코드를 완성하세요.

- **(7-1) 아래 가이드에 따라 데이터를 처리하는 코드를 작성하고 실행하세요**
  - 대상 데이터프레임 : data_na
  - 와인종류(E_FE_wine_kind) 컬럼의 값들을 아래 기준에 따라 치환하세요
    - 'white|rose|sparkling','red|white|sparkling', 'red|white|rose|sparkling', 'red|sparkling' > 4가지 값을 'sparkling' 으로 치환
    - 'white|sparkling' > 1가지 값을 'white' 로 치환
    - 'red|rose', 'red|white', 'red|rose|sparkling' > 3가지 값을 'red' 로 치환
  - 치환 후 와인종류(E_FE_wine_kind)의 카테고리 별 개수를 출력하세요
  - 아래 코드 셀(cell)에 있는 코드의 빈칸을 채우고 실행하세요
  - 빈칸에 들어갈 내용은 각 답안 셀(cell)에 입력하세요 (#7-1, #7-2)

- **(7-3) 아래 가이드에 따라 결측치를 처리하고 검증하는데 에러가 나고 있습니다. 코드의 오류를 정정하세요**
  - 대상 데이터프레임 : data_na
  - 불필요한 컬럼 5개('E_province', 'E_region_1', 'E_region_2', 'E_winery', 'E_wine_variety')를 삭제하세요
  - 원-핫 인코딩 대상 컬럼은 'E_country', 'E_FE_wine_kind' 2개 입니다
  - 원-핫인코딩이 반영된 결과를 데이터프레임 변수명 data_preset에 저장하세요
  - 원-핫인코딩한 결과, 인코딩 대상 컬럼이 변환되었는지 info 함수로 검증하세요

- **(7-4) data_na의 와인종류(E_FE_wine_kind) 중 'red'의 개수를 작성하세요**

In [9]:
```python
# (코드 셀) 코드의 빈칸을 채우고 실행하세요

data_na.loc[data_na['E_FE_wine_kind'].isin(['white|rose|sparkling','red|white|sparkling', 'red|white|rose|sparkling',
                                            'red|sparkling']), ['E_FE_wine_kind']] = 'sparkling'
data_na.loc[data_na['E_FE_wine_kind'].isin(['white|sparkling']), ['E_FE_wine_kind']] = 'white'
data_na.loc[data_na['E_FE_wine_kind'].isin(['red|rose', 'red|white', 'red|rose|sparkling']), ['E_FE_wine_kind']] = 'red'

print(data_na['E_FE_wine_kind'].value_counts())
```

```
red          42262
white        29126
sparkling     5626
rose          2910
Name: E_FE_wine_kind, dtype: int64
```

In [ ]:
```python
# (7-1) 여기에 답안을 입력하세요(실행 불필요)

isin
```

In [ ]:
```python
# (7-2) 여기에 답안을 입력하세요(실행 불필요)

value_counts
```

In [10]:
```python
# (7-3) 여기에 코드의 오류를 정정하고 실행하세요

data_na = data_na.drop( ['E_province', 'E_region_1', 'E_region_2', 'E_winery', 'E_wine_variety'], axis=1)
data_preset = pd.get_dummies(data = data_na, columns = ['E_country', 'E_FE_wine_kind'], drop_first=True)
data_preset.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 79924 entries, 2 to 90059
Data columns (total 50 columns):
 #   Column                          Non-Null Count  Dtype
---  ------                          --------------  -----
 0   Grade                           79924 non-null  object
 1   E_FE_vintage                    79924 non-null  int64
 2   FE_continent                    79924 non-null  int64
 3   E_price                         79924 non-null  float64
 4   FE_points_location              79924 non-null  float64
 5   FE_points_variety               79924 non-null  float64
 6   FE_points_winery                79924 non-null  float64
 7   E_country_Armenia               79924 non-null  uint8
 8   E_country_Australia             79924 non-null  uint8
 9   E_country_Austria               79924 non-null  uint8
 10  E_country_Bosnia and Herzegovina  79924 non-null  uint8
 11  E_country_Brazil                79924 non-null  uint8
 12  E_country_Bulgaria              79924 non-null  uint8
 13  E_country_Canada                79924 non-null  uint8
 14  E_country_Chile                 79924 non-null  uint8
 15  E_country_Croatia               79924 non-null  uint8
 16  E_country_Cyprus                79924 non-null  uint8
 17  E_country_Czech Republic        79924 non-null  uint8
 18  E_country_England               79924 non-null  uint8
 19  E_country_France                79924 non-null  uint8
 20  E_country_Georgia               79924 non-null  uint8
 21  E_country_Germany               79924 non-null  uint8
 22  E_country_Greece                79924 non-null  uint8
 23  E_country_Hungary               79924 non-null  uint8
 24  E_country_India                 79924 non-null  uint8
 25  E_country_Israel                79924 non-null  uint8
 26  E_country_Italy                 79924 non-null  uint8
 27  E_country_Lebanon               79924 non-null  uint8
 28  E_country_Luxembourg            79924 non-null  uint8
 29  E_country_Macedonia             79924 non-null  uint8
 30  E_country_Mexico                79924 non-null  uint8
 31  E_country_Moldova               79924 non-null  uint8
 32  E_country_Morocco               79924 non-null  uint8
 33  E_country_New Zealand           79924 non-null  uint8
 34  E_country_Peru                  79924 non-null  uint8
 35  E_country_Portugal              79924 non-null  uint8
 36  E_country_Romania               79924 non-null  uint8
 37  E_country_Serbia                79924 non-null  uint8
 38  E_country_Slovakia              79924 non-null  uint8
 39  E_country_Slovenia              79924 non-null  uint8
 40  E_country_South Africa          79924 non-null  uint8
 41  E_country_Spain                 79924 non-null  uint8
 42  E_country_Switzerland           79924 non-null  uint8
 43  E_country_Turkey                79924 non-null  uint8
 44  E_country_US                    79924 non-null  uint8
 45  E_country_Ukraine               79924 non-null  uint8
 46  E_country_Uruguay               79924 non-null  uint8
 47  E_FE_wine_kind_rose             79924 non-null  uint8
 48  E_FE_wine_kind_sparkling        79924 non-null  uint8
 49  E_FE_wine_kind_white            79924 non-null  uint8
dtypes: float64(4), int64(2), object(1), uint8(43)
memory usage: 8.2+ MB
```

In [ ]:
```python
# (7-4) 여기에 답안을 입력하세요(실행 불필요)

42262
```

8. 모델링후에 모델의 성능을 평가할 수 있도록 훈련과 검증 각각에 사용할 데이터셋을 분리하려고 합니다.
와인품질등급(Grade) 컬럼을 레이블값 y로, 나머지 컬럼을 피처값 X로 할당한 후 훈련데이터셋과 검증데이터셋으로 분리하세요.

- 대상 데이터프레임 : data_preset
- 훈련과 검증데이터셋 분리
  - 훈련데이터셋 레이블 : y_train, 훈련데이터셋 피처: X_train
  - 검증데이터셋 레이블 : y_valid, 검증데이터셋 피처: X_valid
  - 훈련데이터셋과 검증데이터셋 비율은 70:30으로 설정하세요
  - 훈련데이터셋과 검증데이터셋의 와인등급 비율을 동일하게 하는 옵션을 설정하세요.
  - 난수 시드는 7로 설정하세요
  - scikit-learn의 train_test_split 함수를 활용하세요

In [12]:
```python
# (8) 여기에 답안코드를 작성하고 실행하세요

from sklearn.model_selection import train_test_split

X = data_preset.drop('Grade', axis=1)
y = data_preset['Grade']


X_train, X_valid, y_train, y_valid = train_test_split(X, y, test_size=0.3, random_state=7, stratify=y)
```

9. 스케일링을 통해 데이터 이상치의 영향도를 낮추려고 합니다.

- **(9-1) 아래 가이드에 따라 스케일링 처리하는데 에러가 나고 있습니다. 코드의 오류를 정정하세요**
  - sklearn.preprocessing에서 StandardScaler 함수를 import하세요
  - StandardScaler 함수를 ss 변수에 지정하세요
  - 훈련데이터에 대해 StandardScaler를 학습시키고 변환을 적용하세요
  - 검증데이터에 학습된 스케일링 기준을 그대로 적용하세요
  - 스케일링된 검증데이터의 가장 큰 값을 찾고, 이를 반올림하세요

- **(9-2) StandardScaler 적용 후 검증데이터의 최댓값을 반올림한 결과는 무엇입니까?**

In [13]:
```python
# (9-1) 여기에 코드의 오류를 정정하고 실행하세요

from sklearn.preprocessing import StandardScaler

ss = StandardScaler()
X_train = ss.fit_transform(X_train)
X_valid = ss.transform(X_valid)
round(np.max(X_valid))
```

Out[13]:
```
237
```

In [ ]:
```python
# (9-2) 여기에 답안을 입력하세요(실행 불필요)

237
```

****

10. 와인품질등급(Grade)을 예측하는 머신러닝 모델을 만들려고 합니다.
DecisionTree와 RandomForest는 여러 규칙을 순차적으로 적용하면서 독립변수 공간을 분할하는 모형으로서, 분류와 회귀 분석에 모두 사용될 수 있습니다.

- **(10-1) DecisionTree 모델의 하이퍼파라미터를 아래와 같이 구성하고, 변수에 저장하세요**
  - Cross Validation 방법론 중 GridSearchCV 사용하여 총 5회의 Cross Validation 수행
  - 트리의 최대 깊이 후보 : [3, 5, 7, 10]
  - 노드를 분할하기 위한 최소한의 샘플 데이터수(min_samples_split) 후보 : [2, 3, 5, 10]
  - GridSearchCV의 scoring 파라미터는 'accuracy', n_jobs 파라미터는 -1 로 설정
  - DecisionTree 모델의 난수 시드 : 7
  - Decision Tree 모델을 gs_dt 변수에 저장하세요
  - 앞서 분리한 훈련데이터셋으로 fit 함수를 사용해 학습시키세요

- **(10-2) RandomForest 모델의 하이퍼파라미터를 아래와 같이 설정하고, 변수에 저장하세요**
  - Cross Validation 방법론 중 GridSearchCV 사용하여 총 5회의 Cross Validation 수행
  - 분류기 개수 후보 : [100, 200, 500]
  - 트리의 최대 깊이 후보 : [5, 10, 20]
  - 노드를 분할하기 위한 최소한의 샘플 데이터수(min_samples_split) 후보 : [2, 5, 10]
  - GridSearchCV의 scoring 파라미터는 'accuracy', n_jobs 파라미터는 -1 로 설정
  - RandomForest 모델의 난수 시드 : 7
  - Random Forest 모델을 gs_rf 변수에 저장하세요
  - 앞서 분리한 훈련데이터셋으로 fit 함수를 사용해 학습시키세요

- **(10-3) Grid Search를 통해 찾아낸 RandomForest의 최적화된 분류기 개수는 몇 개 인가요?**

In [14]:
```python
# (10-1) 여기에 답안코드를 작성하고 실행하세요

from sklearn.tree import DecisionTreeClassifier
from sklearn.model_selection import GridSearchCV

dt = DecisionTreeClassifier(random_state=7)

param_grid_dt = {
    "max_depth": [3, 5, 7, 10],
    "min_samples_split": [2, 3, 5, 10]
}

gs_dt = GridSearchCV(
    estimator=dt,
    param_grid=param_grid_dt,
    cv=5,
    scoring="accuracy",
    n_jobs=-1
)

gs_dt.fit(X_train, y_train)
```

Out[14]:
```
▸          GridSearchCV
 ▸ estimator: DecisionTreeClassifier
      ▸ DecisionTreeClassifier
```

In [15]:
```python
# (10-2) 여기에 답안코드를 작성하고 실행하세요

from sklearn.ensemble import RandomForestClassifier

rf = RandomForestClassifier(random_state=7)

param_grid_rf = {
    "n_estimators": [100, 200, 500],
    "max_depth": [5, 10, 20],
    "min_samples_split": [2, 5, 10]
}

gs_rf = GridSearchCV(
    estimator=rf,
    param_grid=param_grid_rf,
    cv=5,
    scoring="accuracy",
    n_jobs=-1
)

gs_rf.fit(X_train, y_train)
```

Out[15]:
```
▸          GridSearchCV
 ▸ estimator: RandomForestClassifier
      ▸ RandomForestClassifier
```

In [ ]:
```python
# (10-3) 여기에 답안을 입력하세요(실행 불필요)

500
```

11. 모델의 해석력과 개선 방향을 이해하기 위해 RandomForest 모델의 변수중요도를 파악하려고 합니다.

- **(11-1) 아래 가이드에 따라 모델의 변수중요도 파악하는데 에러가 나고 있습니다. 코드의 오류를 정정하세요**
  - Grid Search를 통해 찾은 최적화된 파라미터가 적용된 gs_rf의 best_estimator를 사용하세요
  - 변수중요도 점수와 변수 이름을 매핑하여 DataFrame을 만드세요
  - 변수중요도 점수를 기준으로 내림차순 정렬하고 Top 10 개만 선정하세요
  - 변수중요도 점수를 막대 그래프로 시각화하세요

- **(11-2) 출력된 그래프에서 가장 높은 중요도를 보이는 변수명을 쓰세요**

In [16]:
```python
# (11-1) 여기에 코드의 오류를 정정하고 실행하세요

fi = pd.DataFrame({'feature': X.columns, 'importance': gs_rf.best_estimator_.feature_importances_})
fi = fi.sort_values('importance', ascending=False)[:10]
sns.barplot(x='importance', y='feature', data=fi, palette='viridis')
```

Out[16]:
```
<Axes: xlabel='importance', ylabel='feature'>
```

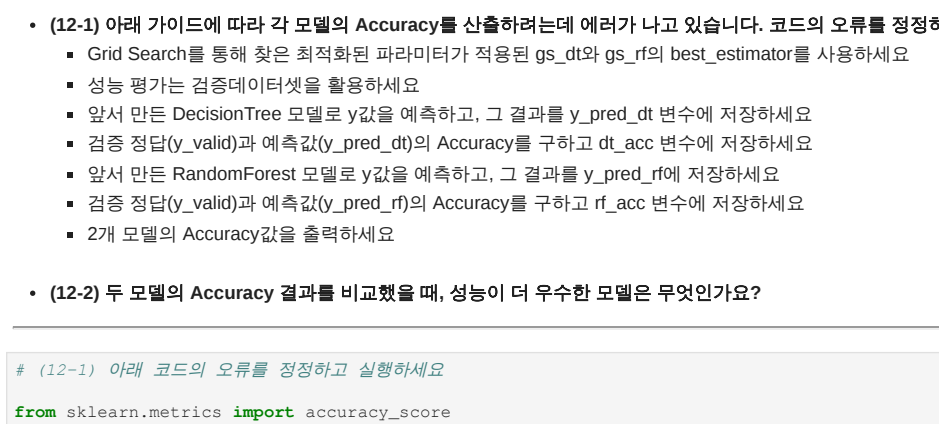

In [ ]:
```python
# (11-2) 여기에 답안을 입력하세요(실행 불필요)

FE_points_winery
```

12. 앞서 학습시킨 DecisionTree와 RandomForest 모델의 성능을 평가하려고 합니다.

- **(12-1) 아래 가이드에 따라 각 모델의 Accuracy를 산출하려는데 에러가 나고 있습니다. 코드의 오류를 정정하세요**
  - Grid Search를 통해 찾은 최적화된 파라미터가 적용된 gs_dt와 gs_rf의 best_estimator를 사용하세요
  - 성능 평가는 검증데이터셋을 활용하세요
  - 앞서 만든 DecisionTree 모델로 y값을 예측하고, 그 결과를 y_pred_dt 변수에 저장하세요
  - 검증 정답(y_valid)과 예측값(y_pred_dt)의 Accuracy를 구하고 dt_acc 변수에 저장하세요
  - 앞서 만든 RandomForest 모델로 y값을 예측하고, 그 결과를 y_pred_rf에 저장하세요
  - 검증 정답(y_valid)과 예측값(y_pred_rf)의 Accuracy를 구하고 rf_acc 변수에 저장하세요
  - 2개 모델의 Accuracy값을 출력하세요

- **(12-2) 두 모델의 Accuracy 결과를 비교했을 때, 성능이 더 우수한 모델은 무엇인가요?**

In [17]:
```python
# (12-1) 아래 코드의 오류를 정정하고 실행하세요

from sklearn.metrics import accuracy_score

y_pred_dt = gs_dt.best_estimator_.predict(X_valid)
y_pred_rf = gs_rf.best_estimator_.predict(X_valid)

dt_acc = accuracy_score(y_valid, y_pred_dt)
rf_acc = accuracy_score(y_valid, y_pred_rf)

print(dt_acc, rf_acc)
```

```
0.8089915756109767 0.8174576695304029
```

In [ ]:
```python
# (12-2) 여기에 답안을 입력하세요(실행 불필요)

RandomForest
```

> **다음 문항을 풀기 전에 아래 코드를 실행하세요.**

In [18]:
```python
import tensorflow as tf
from tensorflow.keras.models import Sequential, load_model
from tensorflow.keras.layers import Dense, Activation, Dropout, BatchNormalization
from tensorflow.keras.callbacks import EarlyStopping, ModelCheckpoint
from tensorflow.keras.utils import to_categorical

tf.random.set_seed(1)
```

13. 와인품질등급(Grade)을 예측하는 딥러닝 모델을 만들려고 합니다.
아래 토폴로지 다이어그램과 가이드를 참고해서 모델링하고 학습을 수행하세요.

- tensorflow framework를 사용하고 하단의 토폴로지 그림과 동일한 딥러닝 모델을 구현하세요
- 히든 레이어의 activation 함수는 'relu'를, 마지막 아웃풋 레이어의 activation 함수는 'sigmoid'를 사용하세요
- EarlyStopping 함수를 사용해서 14번의 epoch 동안 모니터링 지표(val_loss)가 향상되지 않을 경우 훈련을 중지하도록 설정하고 estop 변수에 저장하세요
- optimizer는 adam, metrics는 accuracy, loss는 binary_crossentropy로 지정해서 모델을 컴파일하세요
- 다음 조건에 따라 모델을 학습하고 학습정보는 history 변수에 저장하세요
  - batch_size : 128
  - epoch : 50
- 안내된 내용 외 별도의 파라미터를 입력하지 마세요
- 아래 코드 셀(cell)에 있는 코드의 빈칸을 채우고 실행하세요
- 빈칸에 들어갈 내용은 각 답안 셀(cell)에 입력하세요 (#13-1, #13-2)

cat

In [19]:
```python
# (코드 셀) 코드의 빈칸을 채우고 실행하세요

from sklearn.preprocessing import LabelEncoder

model = Sequential([
    Dense(128, activation='relu', input_dim=X_train.shape[1]),
    Dropout(0.3),
    Dense(64, activation='relu'),
    Dense(32, activation='relu'),
    Dense(2, activation='sigmoid')
])

estop = EarlyStopping(monitor='val_loss', patience=14, restore_best_weights=True)
model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['accuracy'])

le = LabelEncoder()
y_train = le.fit_transform(y_train)
y_valid = le.transform(y_valid)

y_train= to_categorical(y_train)
y_valid = to_categorical(y_valid)

history = model.fit(X_train, y_train,
                    epochs=50,
                    batch_size=128,
                    validation_data=(X_valid, y_valid),
                    callbacks=[estop])
```

```
Epoch 1/50
438/438 [==============================] - 2s 2ms/step - loss: 0.4545 - accuracy: 0.7894 - val_loss: 0.4143 - val_accuracy: 0.8099
Epoch 2/50
438/438 [==============================] - 1s 2ms/step - loss: 0.4231 - accuracy: 0.8041 - val_loss: 0.4095 - val_accuracy: 0.8120
Epoch 3/50
438/438 [==============================] - 2s 4ms/step - loss: 0.4170 - accuracy: 0.8068 - val_loss: 0.4068 - val_accuracy: 0.8130
Epoch 4/50
438/438 [==============================] - 1s 3ms/step - loss: 0.4124 - accuracy: 0.8075 - val_loss: 0.4042 - val_accuracy: 0.8153
Epoch 5/50
438/438 [==============================] - 1s 3ms/step - loss: 0.4109 - accuracy: 0.8084 - val_loss: 0.4033 - val_accuracy: 0.8137
Epoch 6/50
438/438 [==============================] - 1s 3ms/step - loss: 0.4089 - accuracy: 0.8109 - val_loss: 0.4029 - val_accuracy: 0.8150
Epoch 7/50
438/438 [==============================] - 1s 3ms/step - loss: 0.4072 - accuracy: 0.8109 - val_loss: 0.4025 - val_accuracy: 0.8150
Epoch 8/50
438/438 [==============================] - 1s 3ms/step - loss: 0.4060 - accuracy: 0.8106 - val_loss: 0.4013 - val_accuracy: 0.8147
Epoch 9/50
438/438 [==============================] - 1s 3ms/step - loss: 0.4061 - accuracy: 0.8105 - val_loss: 0.4011 - val_accuracy: 0.8167
Epoch 10/50
438/438 [==============================] - 2s 4ms/step - loss: 0.4044 - accuracy: 0.8116 - val_loss: 0.4009 - val_accuracy: 0.8149
Epoch 11/50
438/438 [==============================] - 1s 3ms/step - loss: 0.4031 - accuracy: 0.8115 - val_loss: 0.3995 - val_accuracy: 0.8156
Epoch 12/50
438/438 [==============================] - 1s 3ms/step - loss: 0.4025 - accuracy: 0.8125 - val_loss: 0.4018 - val_accuracy: 0.8147
Epoch 13/50
438/438 [==============================] - 2s 4ms/step - loss: 0.4019 - accuracy: 0.8137 - val_loss: 0.4021 - val_accuracy: 0.8149
Epoch 14/50
438/438 [==============================] - 1s 3ms/step - loss: 0.4021 - accuracy: 0.8122 - val_loss: 0.4002 - val_accuracy: 0.8159
Epoch 15/50
438/438 [==============================] - 1s 3ms/step - loss: 0.4013 - accuracy: 0.8136 - val_loss: 0.4003 - val_accuracy: 0.8149
Epoch 16/50
438/438 [==============================] - 1s 3ms/step - loss: 0.4001 - accuracy: 0.8142 - val_loss: 0.4015 - val_accuracy: 0.8152
Epoch 17/50
438/438 [==============================] - 1s 3ms/step - loss: 0.4004 - accuracy: 0.8141 - val_loss: 0.4006 - val_accuracy: 0.8153
Epoch 18/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3987 - accuracy: 0.8143 - val_loss: 0.3992 - val_accuracy: 0.8142
Epoch 19/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3985 - accuracy: 0.8141 - val_loss: 0.4017 - val_accuracy: 0.8156
Epoch 20/50
438/438 [==============================] - 2s 3ms/step - loss: 0.3983 - accuracy: 0.8153 - val_loss: 0.3995 - val_accuracy: 0.8167
Epoch 21/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3984 - accuracy: 0.8142 - val_loss: 0.4004 - val_accuracy: 0.8151
Epoch 22/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3975 - accuracy: 0.8151 - val_loss: 0.4014 - val_accuracy: 0.8168
Epoch 23/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3969 - accuracy: 0.8151 - val_loss: 0.4019 - val_accuracy: 0.8152
Epoch 24/50
438/438 [==============================] - 2s 3ms/step - loss: 0.3964 - accuracy: 0.8152 - val_loss: 0.3989 - val_accuracy: 0.8155
Epoch 25/50
438/438 [==============================] - 2s 3ms/step - loss: 0.3964 - accuracy: 0.8161 - val_loss: 0.4015 - val_accuracy: 0.8151
Epoch 26/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3955 - accuracy: 0.8167 - val_loss: 0.3995 - val_accuracy: 0.8154
Epoch 27/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3955 - accuracy: 0.8160 - val_loss: 0.4005 - val_accuracy: 0.8165
Epoch 28/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3947 - accuracy: 0.8162 - val_loss: 0.4002 - val_accuracy: 0.8151
Epoch 29/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3942 - accuracy: 0.8163 - val_loss: 0.3991 - val_accuracy: 0.8150
Epoch 30/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3956 - accuracy: 0.8159 - val_loss: 0.3993 - val_accuracy: 0.8172
Epoch 31/50
438/438 [==============================] - 2s 4ms/step - loss: 0.3949 - accuracy: 0.8164 - val_loss: 0.3991 - val_accuracy: 0.8168
Epoch 32/50
438/438 [==============================] - 2s 3ms/step - loss: 0.3935 - accuracy: 0.8165 - val_loss: 0.4002 - val_accuracy: 0.8168
Epoch 33/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3932 - accuracy: 0.8174 - val_loss: 0.3990 - val_accuracy: 0.8168
Epoch 34/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3926 - accuracy: 0.8164 - val_loss: 0.3985 - val_accuracy: 0.8160
Epoch 35/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3936 - accuracy: 0.8171 - val_loss: 0.3988 - val_accuracy: 0.8172
Epoch 36/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3927 - accuracy: 0.8173 - val_loss: 0.3995 - val_accuracy: 0.8155
Epoch 37/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3937 - accuracy: 0.8167 - val_loss: 0.3993 - val_accuracy: 0.8156
Epoch 38/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3920 - accuracy: 0.8191 - val_loss: 0.3991 - val_accuracy: 0.8172
Epoch 39/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3917 - accuracy: 0.8179 - val_loss: 0.3980 - val_accuracy: 0.8167
Epoch 40/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3921 - accuracy: 0.8185 - val_loss: 0.3985 - val_accuracy: 0.8170
Epoch 41/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3909 - accuracy: 0.8173 - val_loss: 0.3985 - val_accuracy: 0.8142
Epoch 42/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3910 - accuracy: 0.8172 - val_loss: 0.3990 - val_accuracy: 0.8163
Epoch 43/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3909 - accuracy: 0.8184 - val_loss: 0.3987 - val_accuracy: 0.8176
Epoch 44/50
438/438 [==============================] - 2s 4ms/step - loss: 0.3908 - accuracy: 0.8190 - val_loss: 0.3972 - val_accuracy: 0.8160
Epoch 45/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3895 - accuracy: 0.8188 - val_loss: 0.3982 - val_accuracy: 0.8173
Epoch 46/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3899 - accuracy: 0.8193 - val_loss: 0.3976 - val_accuracy: 0.8167
Epoch 47/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3904 - accuracy: 0.8192 - val_loss: 0.3973 - val_accuracy: 0.8176
Epoch 48/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3891 - accuracy: 0.8197 - val_loss: 0.3979 - val_accuracy: 0.8163
Epoch 49/50
438/438 [==============================] - 1s 3ms/step - loss: 0.3890 - accuracy: 0.8197 - val_loss: 0.3978 - val_accuracy: 0.8176
Epoch 50/50
438/438 [==============================] - 2s 3ms/step - loss: 0.3889 - accuracy: 0.8201 - val_loss: 0.4007 - val_accuracy: 0.8179
```

In [20]:
```python
# (13-1) 여기에 답안을 입력하세요(실행 불필요)

Dense(128, activation='relu', input_dim=X_train.shape[1]),
Dropout(0.3),
Dense(64, activation='relu'),
Dense(32, activation='relu'),
Dense(2, activation='sigmoid')
```

Out[20]:
```
<keras.src.layers.core.dense.Dense at 0x1d439e19ed0>
```

In [ ]:
```python
# (13-2) 여기에 답안을 입력하세요(실행 불필요)

patience
```

14. 앞서 만든 딥러닝 모델의 일반화 성능(Generalization Performance)을 평가하려고 합니다. matplotlib 라이브러리 활용해서, 학습 Accuracy와 검증 Accuracy의 변화를 그래프로 시각화하세요.

- 아래 가이드에 따라 Accuracy 변화를 시각화하는 코드를 완성하세요
  - 1개의 그래프에 학습 Accuracy과 검증 Accuracy 2가지를 모두 표시하세요
  - 위 2가지 각각의 범례를 'acc', 'val_acc'로 표시하세요
  - 그래프의 타이틀은 'Model Accuracy'로 표시하세요
  - X축에는 'Epochs'라고 표시하고 Y축에는 'Accuracy'라고 표시하세요

In [21]:
```python
# (14) 여기에 답안코드를 작성하고 실행하세요

plt.plot(history.history["accuracy"])
plt.plot(history.history["val_accuracy"])
plt.title("Model Accuracy")
plt.xlabel("Epoch")
plt.ylabel("Accuracy")
plt.legend(['acc', 'val_acc'])
plt.show()
```

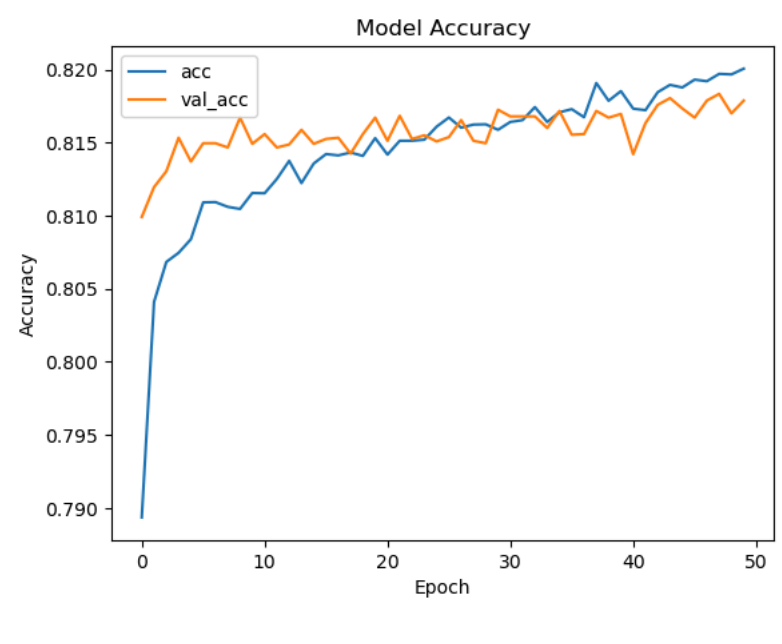

모든 문항이 완료되었습니다. 수고하셨습니다.
'최종제출 및 종료'를 클릭하셔서 답안을 제출해 주시기 바랍니다.